

Documento de Estruturação Experimental

1. Definição do Problema e Escopo

- **Contexto:** Sistemas de Processamento de Linguagem Natural (NLP) em cenários de dados escassos (*few-shot*) frequentemente sofrem com problemas de superconfiança preditiva, falhando ao encontrar dados anômalos.
- **Objetivo:** Desenvolver, implementar e validar uma arquitetura híbrida (LAQDA + SGR) que otimize a classificação seletiva e permita uma gestão de risco rigorosa.
- **Hipótese Central:** O trabalho assume que a classificação seletiva e a detecção OOD podem ser tratadas de forma unificada através da geometria do espaço latente. A hipótese é que a estruturação explícita desse espaço via Transporte Ótimo possa reduzir a sobreposição semântica entre classes em cenários *few-shot*, permitindo que mecanismos seletivos baseados em risco operem com maior separabilidade geométrica entre distribuições ID (*In-Distribution*) e OOD (*Out-of-Distribution*).
- **Limitação Deliberada e Escopo de OOD:** O cenário principal avaliado corresponde ao Semantic OOD (via *Hold-out Classes* intra-domínio, ex: intenções não vistas). Complementarmente, será testado um cenário de Far-OOD (*Domain Shift*, ex: OOD vindo de um domínio totalmente distinto) para avaliar a robustez geral do sistema.

2. Fundamentação da Arquitetura e Pipeline de Decisão

O modelo atua unindo aprendizagem de representação e decisão de risco. A arquitetura segue uma *pipeline* estritamente desacoplada:

1. **Representação:** Um Encoder Transformer base extrai as características textuais.
2. **Otimização do Espaço:** O *Label Adapter* (LAQDA) aplica Transporte Ótimo para aproximar instâncias da mesma classe e afastar distribuições distintas.
3. **Função de Score:** Extração da distância geométrica (ex: Cosseno, Euclidiana ou Mahalanobis) da amostra em relação aos protótipos estabelecidos.
4. **Threshold Seletivo (SGR):** O módulo SGR atua como um mecanismo formal de controle de risco seletivo, aplicando um limiar de corte baseado em quantis empíricos da distribuição ID e calibrado sob garantia probabilística de cobertura.
5. **Decisão:** Classificação Seletiva binária (Aceitar a predição / Abster-se como incerta ou anômala).

3. Estratégia de Dados e Criação do Cenário OOD

A amostragem garantirá o controle de balanceamento para evitar viés de classe e vazamento de dados (*data leakage*).

- **Seleção e Particionamento Reprodutível:** Definição do corpus base (repositório datasets-br-nlp). As classes que comporão o *Semantic OOD* serão fixadas previamente, com *splits* reprodutíveis (ex: 60% ID, 40% OOD estrito).
- **Conjuntos de Treino e Validação (*Few-Shot Fixo*):** Amostragem estritamente balanceada com experimentos fixados em configurações exatas de **1-shot, 5-shot, 10-shot e 15-shot** por classe ID, permitindo avaliar a curva de ganho marginal.
- **Conjunto de Teste:** Composição mista, exigindo do modelo a capacidade de classificar instâncias ID e abster-se nas instâncias OOD.

4. Setup Experimental e Infraestrutura

- **Modelos Base:** Transformers pré-treinados consolidados (ex: BERTimbau ou RoBERTa).
- **Reprodutibilidade e Mitigação de Viés:** Utilização de *seeds* públicas e 5 inicializações aleatórias distintas para a amostragem *few-shot*.
- **Protocolo Estatístico:** A fim de garantir o rigor comparativo, os resultados reportarão a média, o desvio padrão e serão submetidos a testes de significância estatística (Teste de *Wilcoxon Signed-Rank* ou Teste t Pareado, com $p < 0.05$) entre a arquitetura proposta e os baselines.

5. Avaliação Experimental Incremental (*Ablation Study*)

A validação isola o impacto de cada componente metodológico:

- **Degrau 1: Baseline Probabilístico (Limiar Fixo)**
 - *Método:* Maximum Softmax Probability (MSP).
- **Degrau 2: Baselines de Estado da Arte (Geométricos e Baseados em Energia)**
 - *Método:* Mahalanobis Distance (MDF), KNN, *NegPrompt* e métodos focados em calibração energética (*Energy Score* / ODIN).
- **Degrau 3: Otimização de Espaço Latente (LAQDA Puro)**
 - *Método:* Aplicação do LAQDA utilizando apenas score geométrico simples, sem o mecanismo formal de cobertura probabilística do SGR
- **Degrau 4: Arquitetura Proposta Completa (LAQDA + SGR)**
 - *Método:* Integração do LAQDA ao método formal de controle de risco SGR.
- **Degrau 5: Análise Exploratória e Viabilidade Computacional com LLMs**
 - *Método:* Avaliação qualitativa de *Zero-shot/Few-shot* com LLMs (ex: GPT-4 ou LLaMA) configurados com opção de abstenção. Essa etapa atua como benchmark exploratório complementar.

6. Protocolo de Avaliação e Matriz de Métricas

Simulando o cenário real de implantação, a calibração do limite de corte ocorrerá estritamente sobre o conjunto de Validação ID para garantir 95% de cobertura sobre as amostras ID. A utilização de dados OOD para calibrar limiares fere a premissa de *open-world assumption* (onde anomalias são desconhecidas *a priori*) e mascara o risco real do sistema.

Matriz de avaliação:

Eixo de Avaliação	Métrica	Definição e Objetivo da Análise
Classificação Base	Acurácia Global e F1-Score	Mensura a precisão unicamente sobre os dados aceitos pelo modelo.
Calibração	ECE (<i>Expected Calibration Error</i>)	Quantifica o nível de superconfiança (discrepância entre confiança e precisão empírica).
Separação OOD	AUROC	Afere a capacidade intrínseca de separação ID vs. OOD, independentemente do limiar.
Separação OOD	FPR@95	Mede a taxa de amostras OOD aceitas incorretamente quando a cobertura sobre os dados ID é fixada em 95%.
Separação OOD	AUPR-IN / AUPR-OUT	Avalia a separabilidade sob condições de desbalanceamento severo entre os conjuntos ID e OOD.
Predição Seletiva	Curva RC e AURC	Consolida escalarmente (<i>Area Under the Risk-Coverage Curve</i>) o <i>trade-off</i> global da arquitetura.
Predição Seletiva	<i>Selective Risk @ Coverage k</i>	Analisa o risco residual local em pontos operacionais específicos (ex: Risco @ 80% e 90% de Cobertura).

Eixo de Avaliação	Métrica	Definição e Objetivo da Análise
Eficiência Computacional	Parâmetros e Latência	Compara a viabilidade arquitetônica (tamanho em memória, tempo de inferência e custo-benefício) do método proposto frente aos <i>Large Language Models</i> .

7. Contribuições esperadas

- Integração entre estruturação geométrica latente e classificação seletiva.
- Avaliação rigorosa de OOD few-shot em português.
- Protocolo reproduzível de selective classification em NLP.
- Análise de custo-benefício frente a LLMs.